Taller de práctica Examen

La base con la que se trabajará a continuación contiene datos relacionados a la contratación de seguros médicos. Las columnas de la base de datos son las siguientes:

- age: edad en años del beneficiario principal.
- sex: sexo ("female", "male") del beneficiario principal.
- bmi: índice de masa corporal del beneficiario principal.
- children: número de niños cubiertos por el seguro.
- smoker: indica si es ("yes") o no ("no") fumador el beneficiario principal.
- region: el área residencial del beneficiario en los EE. UU., "northeast", "southeast", "southwest", "northwest".
- charges: costos médicos (en dólares) individuales facturados por el seguro de salud.

A continuación, se despliega la siguiente salida de R asociada a un modelo de regresión lineal múltiple

```
##
## Call:
## lm(formula = charges ~ age + sex + region + smoker, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -15726.5  -2066.5  -1296.1   -212.3  28606.9
##
## Coefficients:
##                  Estimate Std. Error t value Pr(>|t|)
## (Intercept)      21509.50     704.17  30.546   <2e-16 ***
## age                275.15      12.46  22.081   <2e-16 ***
## sexfemale          -75.15     350.96  -0.214    0.830
## regionnorthwest   -294.59     502.45  -0.586    0.558
## regionsoutheast    390.35     489.07   0.798    0.425
## regionsouthwest   -436.80     502.45  -0.869    0.385
## smokerno        -23790.26     435.98 -54.567   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6398 on 1331 degrees of freedom
## Multiple R-squared:  0.7221,Adjusted R-squared:  0.7209
## F-statistic: 576.5 on 6 and 1331 DF,  p-value: < 2.2e-16
```

1. Escriba el modelo poblacional.
2. Escriba el modelo ajustado.
3. Escriba la ecuación de regresión ajustada.
4. Interprete los parámetros estimados.
5. Estudie las prueabs de hipótesis de no nulidad y no nulidad conjunta. Utilice una confianza del 95 %. Escriba las hipótesis involucradas.
6. Interprete el R^2 ajustado, y comente porque no es adecuado usar el R^2 para interpretar un modelo de regresión lineal múltiple.
7. Explique el principio de la parsimonia.

8. A continuación, de despliegan distintos gráfico y resultados en R. Utilice los que considere pertinentes para estudiar los supuestos del modelo. Escriba las hipótesis involucradas cuando corresponda. Utilice una confianza del 95 %.

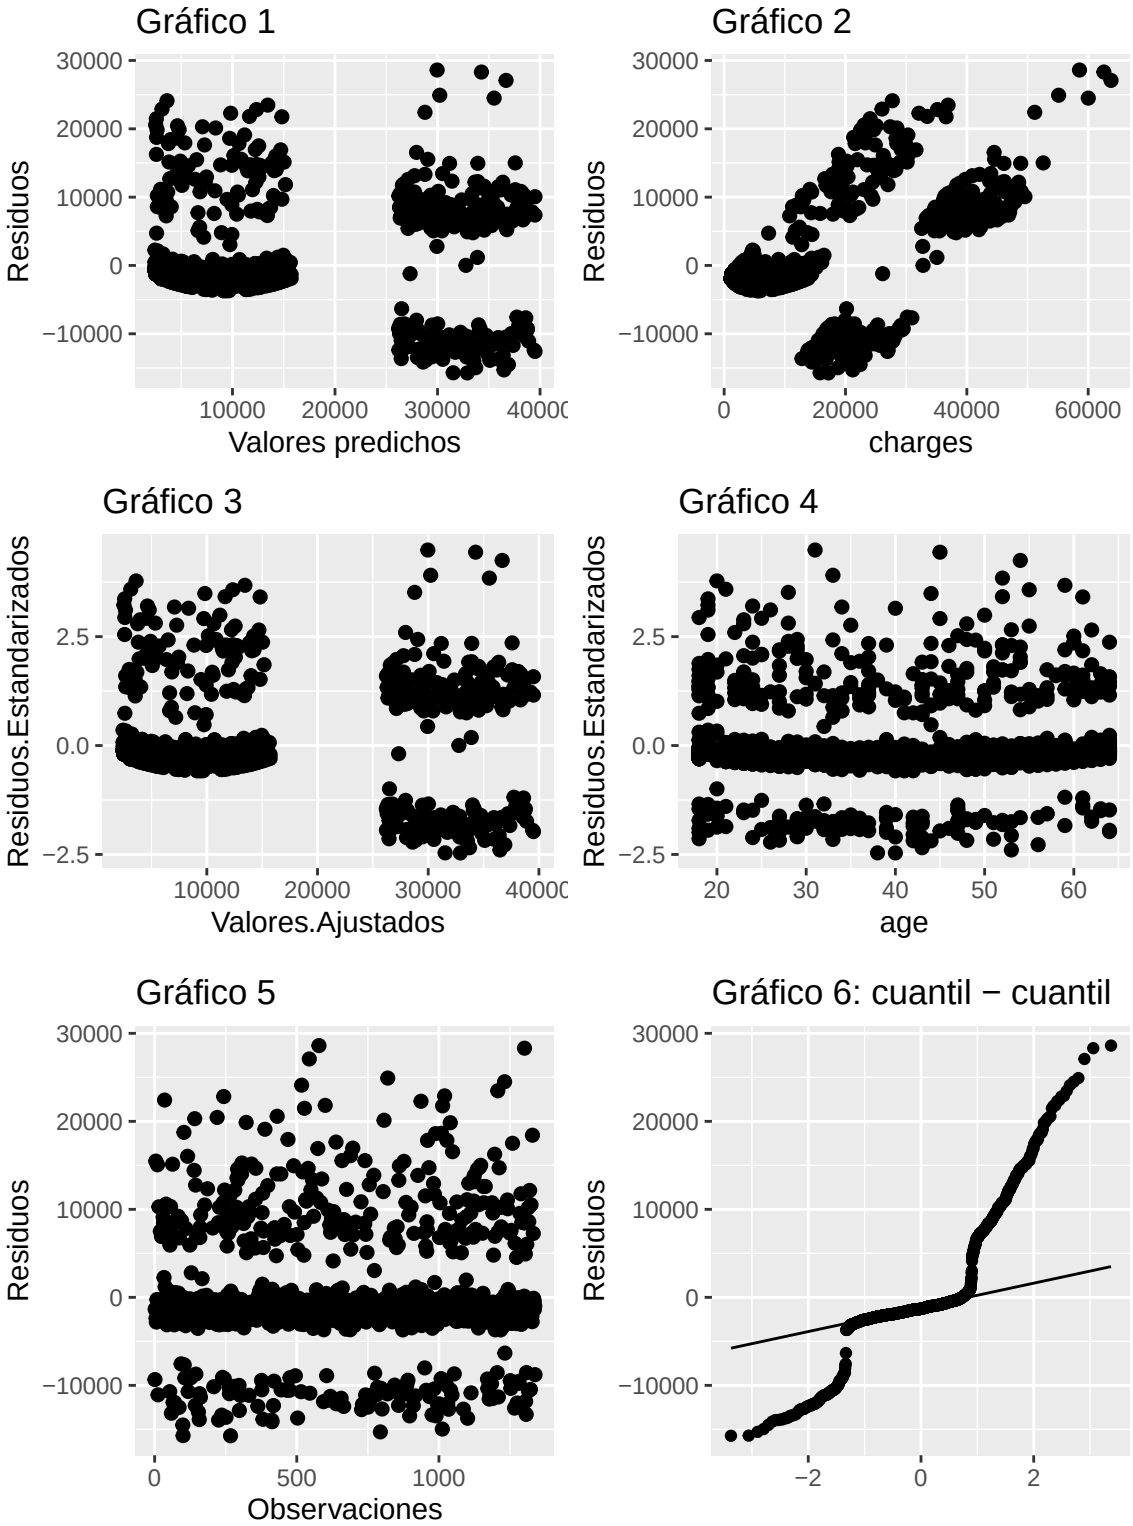


```
##
##  Shapiro-Wilk normality test
##
## data:  df$Valores.Ajustados
```

```
## W = 0.81979, p-value < 2.2e-16
##
##  Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  df$charges
## D = 1, p-value < 2.2e-16
## alternative hypothesis: two-sided
##
##  Shapiro-Wilk normality test
##
## data:  df$Residuos.Estandarizados
## W = 0.82204, p-value < 2.2e-16
##
##  Anderson-Darling normality test
##
## data:  df$Valores.Ajustados
## A = 93.745, p-value < 2.2e-16
```

```
##
##  Durbin-Watson test
##
## data:  age ~ charges + sex + region + smoker
## DW = 1.9826, p-value = 0.7517
## alternative hypothesis: true autocorrelation is not 0
##
##  Durbin-Watson test
##
## data:  charges ~ age + region + smoker
## DW = 2.076, p-value = 0.1644
## alternative hypothesis: true autocorrelation is not 0
##
##  Durbin-Watson test
##
## data:  charges ~ age + sex + region + smoker
## DW = 2.0762, p-value = 0.1629
## alternative hypothesis: true autocorrelation is not 0
```

```
##
##  studentized Breusch-Pagan test
##
## data:  age ~ charges + sex + region + smoker
## BP = 112.51, df = 6, p-value < 2.2e-16
##
##  studentized Breusch-Pagan test
##
## data:  charges ~ age + sex + region + smoker
## BP = 246.9, df = 6, p-value < 2.2e-16
##
##  studentized Breusch-Pagan test
##
## data:  charges ~ age + region + smoker
## BP = 246.66, df = 5, p-value < 2.2e-16
```

9. Explique los siguientes códigos asociados a la base de datos. Sea riguroso en su explicación, escriba toda la terminología estadística involucrada. En particular explique/defina lo siguientes:

- Elabore las hipótesis.
- Explique las variables involucradas en las pruebas (incluyendo los filtros aplicados).
- Interprete el valor-p y los intervalos de confianza como criterio de rechazo, Elaborando una conclusión asociada a la prueba. Utilice una confianza del 95 %.

a)
```r
var.test(x = data$charges[data$smoker == "yes"],
         y = data$charges[data$smoker == "no"],
         conf.level = 0.932,
         alternative = "two.sided")
```

```
##
##  F test to compare two variances
##
## data:  data$charges[data$smoker == "yes"] and data$charges[data$smoker == "no"]
## F = 3.7079, num df = 273, denom df = 1063, p-value < 2.2e-16
## alternative hypothesis: true ratio of variances is not equal to 1
## 93.2 percent confidence interval:
##  3.126519 4.440191
## sample estimates:
## ratio of variances
##           3.707885
```

b)
```r
t.test(x = data$charges[data$smoker == "yes"],
         y = data$charges[data$smoker == "no"],
         conf.level = 0.932,
         mu = 22090,
         alternative = "greater",
         var.equal = T)
```

```
##
##  Two Sample t-test
##
## data:  data$charges[data$smoker == "yes"] and data$charges[data$smoker == "no"]
## t = 3.0153, df = 1336, p-value = 0.001308
## alternative hypothesis: true difference in means is greater than 22090
## 93.2 percent confidence interval:
##  22861.02      Inf
## sample estimates:
## mean of x mean of y
## 32050.232  8434.268
```

c) ¿Que relación tiene el código del ítem *a)* con el del ítem *b)*? ¿Habría que corregir algo para que estuviesen bien planteados ambos en un mismo análisis?