Taller de práctica Prueba 2

Regresión Lineal Simple
(Sección 3.2)

Parte 1

Sean X y Y variables aleatorias de un muestra de tamaño n. Considere el siguiente modelo de regresión lineal simple:

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i, \epsilon_i \overset{iid}{\sim} N(0, \sigma^2)$$

Demuestre que:

1. El estimador de mínimos cuadrados de β_0 es $\widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1 \bar{X}$.
2. $Y = \bar{Y} + r_{XY} \dfrac{S_Y}{S_X}(X - \bar{X})$
3. $R^2 = 1 - \dfrac{\text{SCE}}{\text{SCT}}$
4. $R^2 = r_{XY}^2$

Parte 2

Los dos conjuntos de datos están relacionados con las variantes tinto (link) y blanco (link) del vino portugués "Vinho Verde". Debido a cuestiones de privacidad y logística, sólo están disponibles variables fisicoquímicas (entradas) y sensoriales (salidas) (por ejemplo, no hay datos sobre tipos de uva, marca de vino, precio de venta del vino, etc.).

Las columnas de las bases de datos son las siguientes:

- `fixed.acidity` (g/L): cantidad de la mayoría de los ácidos involucrados con el vino o fijos o no volátiles (no se evaporan fácilmente).
- `volatile.acidity` (g/L): cantidad de ácido acético en el vino, que en niveles demasiado altos puede provocar un sabor desagradable a vinagre
- `citric.acid` (g/L): cantidad de ácido cítrico, que se encuentra en pequeñas cantidades, el cual, puede añadir "frescura" y sabor a los vinos.
- `residual.sugar` (g/L): cantidad de azúcar que queda después de que se detiene la fermentación. Es raro encontrar vinos con menos de 1 gramo/litro y los vinos con más de 45 gramos/litro se consideran dulces.
- `chlorides` (g/L): cantidad de sal en el vino.
- `free.sulfu.dioxide` (ppm): cantidad de la forma libre de SO2 existe en equilibrio entre el SO2 molecular (como gas disuelto) y el ion bisulfito; previene el crecimiento microbiano y la oxidación del vino.
- `total.sulfur.dioxide` (ppm): cantidad de formas libres y ligadas de SO2; En concentraciones bajas, el SO2 es prácticamente indetectable en el vino, pero en concentraciones de SO2 libre superiores a 50 ppm, el SO2 se vuelve evidente en la nariz y el sabor del vino.
- `density` (g/cm^3): densidad del agua dependiendo del porcentaje de alcohol y contenido de azúcar.
- `pH`: describe qué tan ácido o básico es un vino en una escala de 0 (muy ácido) a 14 (muy básico); la mayoría de los vinos tienen entre 3 y 4 en la escala de pH.
- `sulphates` (mg/L): cantidad de aditivo del vino que puede contribuir a los niveles de dióxido de azufre (S02), que actúa como antimicrobiano y antioxidante.
- `alcohol` (ABV, Alcohol por volumen): el porcentaje de alcohol del vino.

- `quality`: variable de salida (basada en datos sensoriales, puntuación entre 0 y 10), un número cercano a 10 indica un vino de mayor calidad.

A continuación, se utiliza la base de datos asociada a los datos del vino tinto para los enunciados siguientes.

1. La siguiente salida de código está asociada a un modelo de regresión lineal. A continuación,

   a) Escriba la ecuación de regresión verdadera.

   b) Escriba la ecuación de regresión ajustada.

   c) Interprete de los parámetros estimados.

   d) Estudie de las hipótesis de no nulidad de cada parámetro por separado. Utilizando una confianza del 95 %. Escriba las hipótesis involucradas.

   e) Interprete del R^2 del modelo.

```
##
## Call:
## lm(formula = pH ~ citric.acid, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.50025 -0.07733 -0.00570  0.08251  0.58251
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.427491   0.005562  616.25   <2e-16 ***
## citric.acid -0.429477   0.016668  -25.77   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1298 on 1597 degrees of freedom
## Multiple R-squared:  0.2937, Adjusted R-squared:  0.2932
## F-statistic:   664 on 1 and 1597 DF,  p-value: < 2.2e-16
```

2. Seleccione los gráficos y/o salidas de R necesarios para estudiar los supuestos del modelo del enunciado anterior. Escriba las hipótesis involucradas cuando corresponda e, interprete utilizando una confianza del 95 %. Justifique la elección de gráficos y códigos a utilizar.

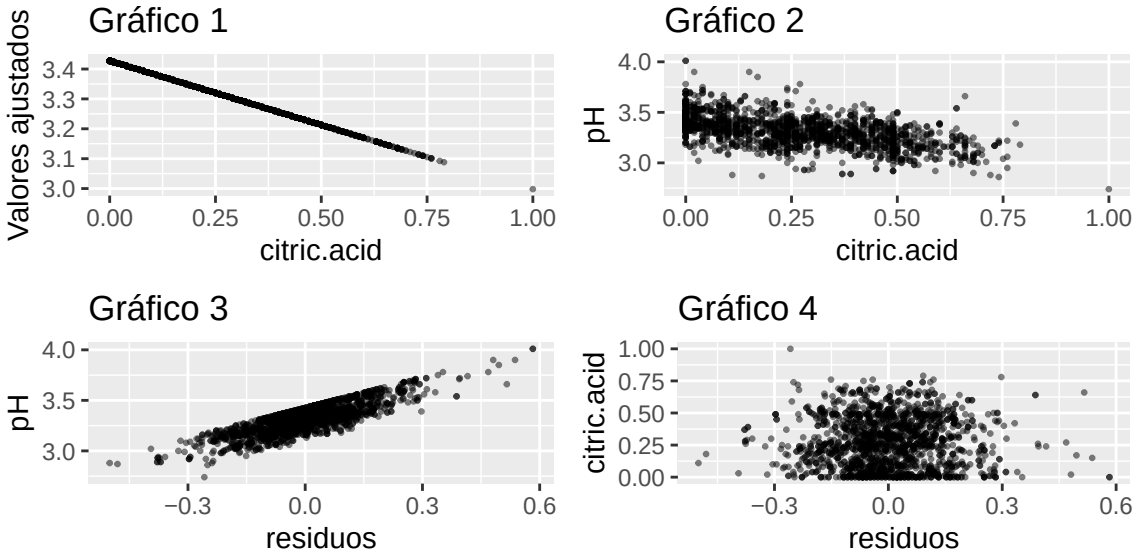

```
##
##  Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  residuals(modelo)
## D = 0.38016, p-value < 2.2e-16
## alternative hypothesis: two-sided
##
##  Shapiro-Wilk normality test
##
## data:  resid(modelo)
## W = 0.98983, p-value = 4.013e-09
##
##  Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  rstandard(modelo)
## D = 0.030333, p-value = 0.1055
## alternative hypothesis: two-sided
##
##  Shapiro-Wilk normality test
##
## data:  modelo$fitted.values
## W = 0.95529, p-value < 2.2e-16
```

```
##
##  studentized Breusch-Pagan test
##
## data:  citric.acid ~ pH
## BP = 10.943, df = 1, p-value = 0.0009394
##
##  studentized Breusch-Pagan test
##
## data:  pH ~ citric.acid + alcohol
## BP = 1.1634, df = 2, p-value = 0.5589
##
##  studentized Breusch-Pagan test
##
## data:  pH ~ fixed.acidity
## BP = 11.677, df = 1, p-value = 0.0006328
##
##  studentized Breusch-Pagan test
##
## data:  pH ~ citric.acid
## BP = 2.437, df = 1, p-value = 0.1185
```

```
##
##  Durbin-Watson test
##
## data:  citric.acid ~ pH
## DW = 1.4601, p-value < 2.2e-16
## alternative hypothesis: true autocorrelation is greater than 0
##
##  Durbin-Watson test
##
## data:  citric.acid ~ alcohol
```

```
## DW = 1.3927, p-value = 1
## alternative hypothesis: true autocorrelation is less than 0
##
##  Durbin-Watson test
##
## data:  pH ~ citric.acid
## DW = 1.6173, p-value = 1.804e-14
## alternative hypothesis: true autocorrelation is not 0
##
##  Durbin-Watson test
##
## data:  pH ~ citric.acid
## DW = 1.6173, p-value = 9.018e-15
## alternative hypothesis: true autocorrelation is greater than 0
```